

Studi Kasus Deteksi Fraud Keuangan

Evaluasi Kritis Data Leakage &
Optimasi Keputusan Berbasis Biaya Bisnis

Model dilatih pada ~5 juta observasi historis · Diuji pada 1.27 juta observasi masa depan (Time-Based Split 80/20)

~6.3Jt

Total Observasi

3

Model ML

99.51%

Recall RF

Rp 21Jt

Risiko Financial

PROJECT OVERVIEW

LATAR BELAKANG

Penipuan keuangan digital terus meningkat secara global. Sistem berbasis aturan konvensional tidak lagi mampu mengikuti pola penipuan yang semakin kompleks dan adaptif.

TUJUAN

Membangun sistem klasifikasi transaksi fraud dengan optimasi threshold berbasis biaya bisnis nyata, sekaligus mengevaluasi secara kritis potensi data leakage pada data sintetis.

DATASET

PaySim Synthetic Financial Dataset (Kaggle)

~5 Juta observasi historis → Training
1.27 Juta observasi masa depan → Test
(Time-Based Split 80/20 — kronologis)

PIPELINE PROYEK

01

Data Preparation & Memory Optimization

Load dataset, downcasting int64→int32/int8 untuk efisiensi memori, feature engineering (amount_vs_balance_orig, transaction_hour)

02

Anti-Leakage Time-Based Split

Pemisahan data secara kronologis 80/20 — masa lalu untuk training, masa depan untuk testing. Mencegah data leakage dari random split.

03

Model Training (3 Algoritma)

Training RF, XGBoost, LightGBM dengan early stopping & class weighting untuk imbalanced data

04

Financial Threshold Optimization


Pencarian threshold berbasis minimasi kerugian finansial riil, bukan F1-Score maksimum (cost-sensitive decision)

05

SHAP Explainability & Critical Evaluation

Analisis SHAP + evaluasi kritis dataset artifact (amount_vs_balance_orig) untuk memastikan model siap produksi

Diagram Alir Metodologi — Dari Raw Data ke Keputusan Bisnis



Perbandingan Performa Model (Optimal + Early Stopping + Threshold)

✂ FASE 2: TRAINING FINAL (OPTIMAL + EARLY STOPPING + THRESHOLD)

▶ Training Random Forest...

✓ Selesai dalam 622.98 detik

✓ Threshold terbaik: 0.70

✓ Total Kerugian Realita: Rp 21,000,000

✓ Rata-rata Kerugian per Transaksi: Rp 16.50

[Confusion Matrix]:

Normal (TN): 1268270 | Salah Tuduh (FP): 0

Lolos (FN): 21 | Berhasil Ditangkap (TP): 4233

▶ Training XGBoost...

✓ Selesai dalam 1026.47 detik

✓ Threshold terbaik: 0.20

✓ Total Kerugian Realita: Rp 195,000,000

✓ Rata-rata Kerugian per Transaksi: Rp 153.24

[Confusion Matrix]:

Normal (TN): 1267530 | Salah Tuduh (FP): 740

Lolos (FN): 158 | Berhasil Ditangkap (TP): 4096

▶ Training LightGBM...

✓ Selesai dalam 179.07 detik

✓ Threshold terbaik: 0.85

✓ Total Kerugian Realita: Rp 327,750,000

✓ Rata-rata Kerugian per Transaksi: Rp 257.56

[Confusion Matrix]:

Normal (TN): 1266635 | Salah Tuduh (FP): 1635

Lolos (FN): 246 | Berhasil Ditangkap (TP): 4008

🏆 HASIL AKHIR

	Nama Model	Waktu (Detik)	Threshold	Akurasi	Recall	Precision	F1-Score	ROC-AUC	PR-AUC
0	Random Forest	622.9800	0.7000	1.0000	0.9951	1.0000	0.9975	1.0000	1.0000
1	XGBoost	1026.4700	0.2000	0.9993	0.9828	0.8470	0.9012	0.9999	0.9828
2	LightGBM	179.0700	0.8500	0.9985	0.9422	0.7103	0.8099	0.9912	0.8060

Random Forest

★ TERBAIK

100%

Akurasi

1.000

ROC-AUC

99.51%

Recall

1.000

PR-AUC

100%

Precision

0.70

Threshold

0.9975

F1-Score

623s

Waktu

XGBoost

99.93%

Akurasi

0.9999

ROC-AUC

96.29%

Recall

0.9828

PR-AUC

84.70%

Precision

0.20

Threshold

0.9012

F1-Score

1026s

Waktu

LightGBM

99.85%

Akurasi

0.9912

ROC-AUC

94.22%

Recall

0.8060

PR-AUC

71.03%

Precision

0.85

Threshold

0.8099




F1-Score

179s

Waktu

Fitur Berpengaruh dalam Mendeteksi Penipuan — dengan Catatan Kritis

Top 10 Feature Importance: Apa yang Dilihat AI?



⚠ CATATAN KRITIS — DATASET ARTIFACT:

amount_vs_balance_orig adalah fitur paling dominan karena sifat deterministik data sintesis PaySim — pada data nyata, rasio ini tidak akan memberikan sinyal sempurna ini.

amount_vs_balance_orig ★

Fitur rekayasa #1 di RF & XGBoost — namun perlu diverifikasi di data nyata karena merupakan dataset artifact.


Tipe Transaksi (CASH_OUT / TRANSFER)

Sinyal fraud yang lebih robust karena berlaku di data nyata, tidak hanya di sintesis.


transaction_hour — Fitur Behavioral

Andalan di produksi: pola waktu transaksi bersifat genuine dan tidak deterministik seperti rasio saldo.

Interpretasi Model: Mengapa Transaksi Diklasifikasi sebagai Fraud?



SHAP Beeswarm Plot



SHAP Feature Importance (Mean |SHAP|)

+0.33

SHAP amount_vs_balance_orig

Kontributor #1 — namun merupakan dataset artifact; perlu konfirmasi di data nyata

-0.4

Skala SHAP bersih (-0.4 to +0.33)


Distribusi bersih mengindikasikan model belajar pola genuine, bukan noise

99.51%


Recall — Hampir Tidak Ada Fraud Lolos

Hanya 21 kasus fraud terlewat dari lebih dari 4000+ kasus yang ada

Interpretasi XGBoost: Pola Penipuan yang Lebih Beragam



SHAP Beeswarm Plot



SHAP Feature Importance (Mean |SHAP|)

+3.85

SHAP amount_vs_balance_orig

Kontributor terkuat — skala jauh lebih besar dari RF, rentan terhadap artifact

+1.75

SHAP type_CASH_OUT


Sinyal kedua terkuat — lebih robust karena tidak tergantung deterministik saldo

Rp 195Jt


Total Kerugian Riil

158 fraud terlewat karena recall 96.29% — kalah dari RF untuk kasus bisnis ini

Interpretasi LightGBM: Cepat namun dengan Trade-off Deteksi



SHAP Beeswarm Plot



SHAP Feature Importance (Mean |SHAP|)

+2293

SHAP amount_vs_balance_orig

Skala raw score sangat besar — bukan probabilitas, perlu normalisasi untuk interpretasi

+1712

SHAP transaction_hour

LightGBM sangat bergantung pada fitur temporal — ini justru lebih robust di produksi

Rp 328Jt

Kerugian Tertinggi

Recall hanya 94.22% — 246 fraud lolos, trade-off kecepatan training yang terlalu mahal

Mengapa Random Forest adalah Pilihan Terbaik?

★ RANDOM FOREST — MODEL TERPILIH · Akurasi 100% · Recall 99.51% · Precision 100% · F1 0.9975 · ROC-AUC 1.000 · Threshold 0.70 · Kerugian Rp 21 Juta

1 Recall 99.51% — Hampir Tidak Ada Fraud Lolos

Hanya 21 transaksi fraud yang terlewat dari ribuan kasus. Dibanding XGBoost (158 fraud lolos, Rp 195Jt) dan LightGBM (246 fraud lolos, Rp 328Jt) — selisih kerugian yang sangat signifikan secara bisnis.

2 Kerugian Finansial Terendah (Rp 21 Juta)

Threshold 0.70 dipilih berdasarkan minimasi kerugian finansial riil, bukan sekadar nilai statistik. Hasilnya 9x lebih kecil dari XGBoost dan 15x lebih kecil dari LightGBM.

3 Zero False Positive (FP = 0)

XGBoost menghasilkan 740 FP dan LightGBM 1,635 FP — transaksi pelanggan sah yang salah diblokir. RF tidak menghasilkan satu pun false alarm, menjaga customer experience tetap baik.

4 Konsistensi SHAP — Distribusi Bersih

SHAP RF menunjukkan rentang -0.4 hingga $+0.33$ yang jauh lebih mudah diinterpretasi dibanding XGBoost (-7 s/d $+7$) atau LightGBM (-40 rb s/d $+20$ rb). Ini penting untuk komunikasi ke stakeholder bisnis.

5 Threshold Intuitif (0.70)

Threshold RF 0.70 mencerminkan keyakinan model yang seimbang. XGBoost 0.20 terlalu agresif (menimbulkan FP masif) dan LightGBM 0.85 terlalu konservatif (melewatkan banyak fraud).

6 Catatan: Validasi Lanjutan Tetap Diperlukan

Hasil RF yang sangat baik sebagian dipengaruhi oleh sifat deterministik dataset sintetis. Langkah berikutnya: k-fold CV, uji di dataset nyata, dan monitoring distributional drift di produksi.

Perbandingan Lengkap: Metrik, Biaya, dan Business Impact

Kriteria	Random Forest ★	XGBoost	LightGBM
Akurasi	100% ✓	99.93%	99.85%
Recall	99.51% ✓	96.29%	94.22%
Precision	100.00% ✓	84.70%	71.03% ✗
F1-Score	0.9975 ✓	0.9012	0.8099 ✗
ROC-AUC	1.0000 ✓	0.9999	0.9912
PR-AUC	1.0000 ✓	0.9828	0.8060 ✗
False Positive (FP)	0 ✓ (terbaik)	740 ✗	1,635 ✗ ✗
False Negative (FN)	21 ✓	158 ✗	246 ✗ ✗
Threshold	0.70 (intuitif)	0.20 (agresif)	0.85 (konservatif)
Kerugian Finansial	Rp 21 Juta ✓	Rp 195 Juta ✗	Rp 328 Juta ✗ ✗
Waktu Training	623 detik	1,026 detik ✗	179 detik ✓
Rekomendasi	PILIH ✓	Alternatif	Tidak Direkomendasikan

Jujur tentang Keterbatasan Model demi Kepercayaan di Industri

⚠ LIMITASI YANG HARUS DIAKUI

L1 Dataset Sintetis → Hasil Sangat Baik Perlu Dikonfirmasi

PaySim adalah data simulasi. Fitur `amount_vs_balance_orig` adalah dataset artifact — di data nyata polanya tidak sejernih ini. Meski sudah pakai time-based split, validasi di data nyata tetap wajib.

L2 Belum Ada K-Fold Cross-Validation

Model diuji pada satu split kronologis. K-fold stratified (min. 5-fold) diperlukan untuk memastikan konsistensi performa, terutama mengingat kemungkinan pengaruh artifact di training set.

L3 Tidak Ada Uji Distributional Shift

Model tidak diuji pada pola fraud baru yang belum pernah dilihat. Di industri, pola fraud berevolusi cepat — monitoring drift berkala adalah keharusan setelah deployment.

→ NEXT STEPS UNTUK PRODUKSI

01 Validasi dengan K-Fold Stratified CV

5-fold atau 10-fold stratified CV. Jika $\text{mean F1} \geq 0.90$ dengan std dev rendah, model layak dipercaya untuk produksi.

02 Uji pada Data Nyata / IEEE-CIS Dataset

Validasi model di dataset transaksi nyata. Terutama periksa apakah `amount_vs_balance_orig` masih menjadi fitur dominan — jika tidak, retrain tanpa fitur tersebut.

03 Model Monitoring & Drift Detection

Gunakan Evidently AI atau WhyLogs. Tetapkan alert jika recall turun $> 5\%$ — yang berarti fraud baru mulai lolos.

04 Ensemble / Hybrid dengan Rule-Based

Kombinasikan RF dengan rule-based system untuk edge case. Atau stacking RF + XGBoost untuk robustness yang lebih baik di data nyata.

Random Forest adalah Model Optimal untuk Deteksi Fraud Keuangan

Risiko Financial Rp 21 Juta membuktikan bahwa performa machine learning berdampak langsung pada fundamental bisnis — bukan sekadar angka statistik.

Dari tiga model yang diuji dengan time-based split, Random Forest terbukti terbaik secara teknis maupun bisnis, dengan catatan validasi lanjutan tetap diperlukan.

- ✓ Time-based split memastikan evaluasi yang realistis dan bebas data leakage
- ✓ Financial threshold optimization menghubungkan ML langsung ke keputusan bisnis (Rp 21Jt)
- ✓ Dataset artifact diakui secara transparan — amount_vs_balance_orig perlu validasi di data nyata
- ✓ SHAP explainability memungkinkan model dapat dipercaya oleh stakeholder non-teknis

TECH STACK

Python

Scikit-learn

XGBoost

LightGBM

SHAP

Pandas

NumPy

Matplotlib

